

מטלת סיכום – חלק 2

דוח מסכם: חיזוי דירוג סרטים ב-IMDb

שמות הסטודנטים: כפיר זיסו ויעל בוקריס

תעודות זהות: 322883091

תאריך הגשה: 29.05.2026

1. הקדמה ותיאור הנתונים

1.1 מטרת הפרויקט

הפרויקט עוסק בבניית מודל רגרסיה מבוסס למידת מכונה לחיזוי הדירוג הממוצע של סרטים בפלטפורמת IMDb החיזוי מבוצע על בסיס מאפיינים שונים של הסרט הזמינים במלואם טרם יציאתו לאקרנים (כגון אורך, ז'אנר, שפה, מדינת הפקה, מאפייני קאסט ושנת יציאה) מטרת המחקר היא לזהות אילו גורמים תורמים ביותר לחיזוי הדירוג, להשוות מתודולוגית בין אלגוריתמים שונים, ולבחון את הגינות (Fairness) המודל המופק בין חתכים שונים של אוכלוסיית הדאטה.

2.1 תיאור מערך הנתונים

מערך הנתונים המקורי מכיל רשומות רבות הכוללות מידע מבני וטקסטואלי. כחלק מתהליך הניקוי והכנת הנתונים, הוסרו רשומות שבהן משתנה המטרה (averageRating) היה חסר. מערך הנתונים הסופי שעליו אומנו והוערכו המודלים כולל 115,560 שורות (סרטים) ו-13 עמודות. המשתנים הנומריים והקטגוריאליים עברו סיווג והכנה ייעודית בתוך פונקציית העיבוד prepare_data טרם הזרמתם ל-Pipeline-האימון.

2. פונקציית העיבוד המרכזית

ארכיטקטורת פונקציית prepare_data

בהתאם לדרישות הטכניות, הוגדרה פונקציה אחידה, דטרמיניסטית ורובוסטית בשם prepare_data(df) הפונקציה מקבלת DataFrame במבנה הגולמי ומבצעת את השלבים הבאים:

- המרות טיפוסים וניקוי ערכים חסרים קשיחים: משך הסרט (runtimeMinutes) ושנת היציאה (startYear) מומרים לטיפוסים נומריים. שנים שאינן בטווח הגיוני (קטנות מ-1000 או גדולות מ-9999) מוחלפות ב NaN-לשם טיפול בהמשך הצינור.
- סטנדרטיזציה של טקסטים: עמודות ה-genres וה-lead_actors_ids עוברות ניקוי תווים מיוחדים (כגון סוגריים מרובעים וגרשיים) וטקסטים המייצגים ערכים חסרים במאגר (כמו '\') מומרים למחרוזות ריקות.

3. סינון מדינות ושפות: (Domain Knowledge) עמודות המדינה והשפה ממופות אל מול רשימות מוגדרות מראש של הישויות הנפוצות והרלוונטיות ביותר בתעשייה, תוך איחוד שמות זהים (למשל, איחוד 'United States' ו-'USA')
4. הסרת משתני Data Leakage: עמודות ה- numVotes ו-BoxOffice מוסרות מהדאטה באופן מוחלט, שכן הן אינן ידועות בזמן יציאת הסרט לאקרנים.

3. הנדסת מאפיינים (Feature Engineering)

במסגרת תהליך הנדסת המאפיינים, (Feature Engineering) יוצרו 6 פיצ'רים חדשים המבוססים על ידע ספציפי מעולם הקולנוע:

שם המאפיין	נוסחה / מקור	מוטיבציה
genre_count	ספירת מספר הז'אנרים שסרט שייך אליהם (split על ';', בעמודת genres)	סרטים מרובי-ז'אנר עשויים להיות מורכבים יותר ולקבל דירוגים שונים
is_post_imdb	1 אם $\text{startYear} \geq 1990$, אחרת 0 (שנת ייסוד IMDb)	סרטים שיצאו אחרי ייסוד IMDb זוכים לכיסוי דירוגים שונה
num_a_list_actors	ספירת שחקנים ראשיים מתוך רשימת שחקני A-list	נוכחות שחקנים מובילים משפיעה על ציפיות ועל דירוג
is_english	1 אם השפה היא English, אחרת 0	סרטים בשפה האנגלית מגיעים לקהל רחב יותר
is_usa	1 אם מדינת ההפקה היא USA, אחרת 0	הפקות אמריקאיות שולטות בפלטפורמה ועשויות להיות בעלות הטיית דירוג
runtime_category_num	קטגוריזציה של אורך הסרט: 1=קצר (<60'), 2=סטנדרטי (60-120'), 3=ארוך (>120')	אורך הסרט קשור לסוג הסרט ולציפיות הצופים
genres על One-Hot	עמודה בינארית לכל ז'אנר עיקרי (Drama, Comedy, Thriller, Horror, Sci-Fi, Documentary וכו')	ייצוג קטגוריאלי המאפשר למודל לזהות השפעת ז'אנר ספציפי

בסך הכול הונדסו 6 מאפיינים חדשים, בנוסף לקידוד One-Hot של הז'אנרים. מאפיינים אלה משולבים עם המאפיינים המספריים המקוריים (runtimeMinutes, numVotes) ואחרים במטריצת הפיצ'רים הסופית.

4. בחירת מודלים ומתודולוגיה

1.4 המודלים שנבחרו

נבחרו שני מודלים בעלי גישות שונות מהותית:

Elastic Net Regression – מודל לינארי עם רגולריזציה משולבת, $(L1 + L2)$, המאפשר גם בחירת מאפיינים (sparsity) וגם יציבות בנוכחות מולטי-קולינאריות.

Random Forest Regressor – מודל אנסמבל לא-לינארי, המבוסס על עצי החלטה. נבחר במקום עץ החלטה בודד מכיוון שהוא מפחית משמעותית את שונות החיזוי (variance reduction) באמצעות מיצוע על מאות עצים, ומסוגל ללכוד אינטראקציות בין מאפיינים. הבחירה משלימה את המודל הלינארי באופן טבעי.

2.4 חלוקת אימון-בדיקה | Cross-Validation-

הנתונים חולקו ל-80% אימון ו-20% בדיקה (test set) באקראי עם seed קבוע. על מערך האימון בוצע 10-fold Cross-Validation לכל מודל, כך שכל קיפול שימש פעם אחת כוולידציה ותשע פעמים כאימון. כל שלבי העיבוד (imputation, scaling, encoding) שולבו ב-Pipeline והופעלו בתוך כל קיפול בנפרד.

3.4 השוואת ביצועים

הטבלה הבאה מסכמת את ביצועי שני המודלים על ה-10 (fold CV)-ממוצע $\pm$ סטיית תקן:

מדד	Elastic Net	Random Forest
RMSE (ממוצע $\pm$ סטיית תקן)	1.1267 (0.0486)	1.1205 (0.0493)
MAE (ממוצע $\pm$ סטיית תקן)	0.8636 (0.0357)	0.8579 (0.0368)
R^2 (ממוצע $\pm$ סטיית תקן)	0.2368 (0.0223)	0.2452 (0.0233)
היפר-פרמטרים אופטימליים שנבחרו (Best Params)	$\alpha: 0.001, l1_ratio: 0.3$	$max_depth: 10, min_samples_leaf: 4$

ניתוח מתודולוגי והנדסי של התוצאות

- השוואת ביצועים וקביעת המודל המוביל: מודל ה-Random Forest Regressor נקבע כמודל האופטימלי והמוביל בפריקט זה. הוא השיג ציון R^2 גבוה של 0.2452 וציון RMSE נמוך וטוב יותר של 1.1205. היתרון של ה-Random Forest נובע מיכולתו המובנית של אלגוריתם מבוסס עצים ללמוד קשרים לא-ליניאריים מורכבים ואינטראקציות חבויות בין הפיצ'רים הקטגוריאליים (לדוגמה, שילוב של ז'אנר ספציפי עם שפת מקור ומשך הסרט) בצורה גמישה, בעוד שהמודל הלינארי (Elastic Net) על אף ששודרג עם הרחבה פולינומית, נותר מוגבל יחסית ביכולת ההכללה שלו על מבנה הנתונים הספציפי הזה.
- ניתוח כושר ההסבר (R^2): מודל ה-Random Forest מסביר 24.52% מהשונות של דירוג הסרטים באוכלוסייה. בעולם של חיזוי מדדים אמנותיים ותלויי טעם אנושי

(Human-centric metrics) כושר הסבר הקרוב ל-25% נחשב להישג הנדסי מכובד ומקובל לחלוטין. המודל נדרש לנבא ציון של יצירה קולנועית **טרם** שהיא נחשפת לעולם, ללא גישה למשתנים איכותיים מכריעים כגון: איכות הבימוי, רמת התסריט, עריכה, או הבאז החברתי

שנוצר בזמן ההפצה. התוצאות מראות שהמודלים הצליחו למצות את מקסימום המידע מתוך הפיצ'רים המבניים הקיימים.

3. יציבות ורובוסטיות הצינור: סטיות התקן שחושבו על פני 10 ה-Folds הן נמוכות במיוחד (בסביבות 0.02–0.04) בשני המודלים. הדבר מעיד על כך שהמזדים יציבים ועקביים מאוד על פני חלוקות שונות של הדאטה, ומספק הוכחה מתודולוגית לכך שצינור העיבוד (Pipeline) המורכב שנבנה מונע Data Leakage בצורה הרמטית ומבטיח יכולת הכללה אמיתית.

1.5 ניתוח שגיאות – 10 הסרטים עם ה-Overprediction הגדול ביותר

הטבלה הבאה מציגה את 10 הסרטים שהמודל היה אופטימי מדי בחיזוי (חזה דירוג גבוה משמעותית מהדירוג האמיתי):

שם הסרט	דירוג אמיתי	דירוג חזוי	שגיאה
Horseplay: The History of Horse Riding	1.0	7.19	6.19
Justin Bieber: Always Believing	1.0	7.13	6.13
Rape of the Soul	1.7	7.83	6.13
Ramo Trip	1.4	7.40	6.00
Kurz	1.2	7.16	5.96
At the Back of the Screen	1.5	7.34	5.84
Zwischen Glück und Krone	1.2	7.01	5.81
Jasenovac: Istina	1.4	7.18	5.78
Tribalism Is Killing Us	1.3	7.05	5.75
Obama in NC: The Path to History	1.5	7.21	5.71

ניתוח שגיאות – 10 הסרטים עם ה-Underprediction הגדול ביותר

שם הסרט	דירוג אמיתי	דירוג חזוי	שגיאה
Son-nim-1 Cheo-beon-jjae I-ya-gi	9.1	4.29	-4.80
Bukunja Tekunja Mitti: The Cannibals	9.1	4.30	-4.79
Ungleich	9.1	4.35	-4.74
Il Santo Veleno	9.4	4.98	-4.41
Oscuro by Rene Potter	8.6	4.19	-4.40
Of Sound Mind	9.6	5.21	-4.382
Puli Vachindi Meka Chachindi	9.5	5.17	-4.32

Out 2 Kill	9.4	5.09	-4.30
Pulse of the Indigo	9.3	5.00	-4.29
Colour Palette	9.1	4.84	-4.25

2.5 ניתוח איכותי של מקרי בוחן ספציפיים וזיהוי דפוסים

ניתוח מעמיק של חמישה מקרי בוחן מייצגים:

1. Justin Bieber: Always Believing מדד שגיאה: 6.13: סרט תיעודי-מוזיקלי משנת 2012 המתמקד בכוכב הפופ ג'סטין ביבר. הניתוח האלגוריתמי מראה כי המודל זיהה את המאפיינים המבניים היבשים – ז'אנר דוקומנטרי (הזוכה לפרמיה חיובית גבוהה במודל) ושפה אנגלית – ולכן ניפק תחזית אופטימית של 7.13. בפועל, הציון במאגר צנח ל-1.0 המינימלי. שגיאה בוטה זו נובעת מתופעה סוציולוגית מובהקת ברשת המוכרת כ, "Review Bombing"- במסגרתה התארגנו קבוצות אנטי-מעריצים מסיביות במטרה להטות את הציון באופן מלאכותי ללא קשר לאיכות ההפקה הריאלית. מידע על דינמיקות חברתיות מסוג זה אינו נגיש למודל בשלב טרם ההפצה.
2. Horseplay: The History of Horse Riding מדד שגיאה: 6.19+: סרט תיעודי העוסק בהיסטוריה של רכיבה על סוסים. בדומה למקרה הקודם, המודל הטיל משקל חיובי כבד על עצם היות היצירה משויכת לז'אנר הדוקומנטרי, וחישב תחזית של 7.19. ברם, במציאות התברר כי מדובר בהפקה עצמאית, דלת-תקציב, חובבנית ונטולת בקרת איכות קולנועית, שזכתה לביקורות קטלניות מהקהל המצומצם שנחשף אליה (ציון 1.0). המודל, הנסמך על משתנים נומינליים בלבד, חסר את היכולת להעריך "איכות הפקה אובייקטיבית" או "רמת עריכה" בהיעדר פיצ'ר פרוקסי מתאים.
3. Jasenovac: Istina מדד שגיאה: 5.78+: יצירה דוקומנטרית היסטורית-פוליטית משנת 2016 העוסקת במחנה הריכוז יאסנובאץ. המודל חזה לסרט ציון ממוצע-גבוה של 7.18 על בסיס משתני הז'אנר והאורך. עם זאת, נושאים בעלי רגישות גיאופוליטית, לאומית ואידאולוגית גבוהה נוטים לייצר מלחמות נרטיב מקוונות, שבהן גולשים משני צידי המתרחס הפוליטי מגויסים להצביע בציון הקיצוני 1.0 כדי להוריד את ממוצע היצירה. המודל נכשל כאן כיוון שהוא חסר מודעות לקונטקסט התרבותי וההיסטורי הרגיש של כותרת הסרט או התיאור שלו.
4. Of Sound Mind מדד שגיאה: -4.38: סרט דרמה ומתח עצמאי שקיבל במאגר ציון יוצא דופן של 9.6. המודל, השואף להכללה סטטיסטית, ניפק עבורו תחזית שמרנית של 5.21 הקרובה לתוחלת המותנית הכללית של הדאטה. שגיאת תת-החיזוי כאן נובעת מ"בעיית המדגם המצומצם (Small Sample Bias)" האופיינית לסרטי אינדי: מספר המצביעים בפלטפורמה קטן מאוד ואינו מייצג, ומורכב לרוב מאנשי צוות ההפקה, השחקנים ובני משפחותיהם המעניקים באופן גורף את הציון המושלם 10. האלגוריתם "מגן על עצמו" ובצדק נמנע מניבוי ערכים קיצוניים כאלו בהיעדר סימנים הוליוודיים מובהקים.
5. Son-nim-1 Cheo-beon-jjae l-ya-gi מדד שגיאה: -4.80: סרט דרמה קוריאני שזכה להצלחה כבירה וציונו הריאלי עומד על 9.1. המודל כשל ושעבד אותו לתחזית נמוכה של 4.29. המודל הליניארי והעצי כאחד למדו מהדאטה הכללי כי סרטים שאינם דוברי אנגלית ושאינם מופקים בארצות הברית (Non-US) זוכים בממוצע לציונים נמוכים יותר או יציבים פחות. מה שהמודל לא היה מסוגל לדעת בהיעדר מדדי מוניטין מקומיים, הוא שמדובר ביצירת מופת קולנועית נישתית שזכתה לאהדה פנומנלית בקרב קהל היעד המקומי במדינת המקור.

זיהוי דפוסים משותפים ומערכתיים בקרב ה-Outliers:

- אופטימיות יתר מערכתית (Overprediction Patterns): רובם המוחלט של הסרטים שבהם המודל הפגין אופטימיות יתר קיצונית משתייכים לז'אנר הדוקומנטרי, (Documentary) ובפרט

כאלו העוסקים בנושאים פוליטיים, מוזיקליים נישתיים או הפקות קצרות. האלגוריתם למד כלל אצבע מובהק לפיו הז'אנר הדוקומנטרי מתואם חיובית עם ציונים גבוהים (עקב קהל צופים ממוקד ואוהד בדרך כלל). הכשל המערכתי טמון בחוסר היכולת של המודל לבצע סגמנטציה פנימית בתוך הז'אנר בין יצירות איכותיות עטורות פרסים לבין הפקות חובבניות או סרטים מעוררי מחלוקת החשופים ל Review Bombing-אידיאולוגי.

- פסימיות יתר מערכתית (Underprediction Patterns) קבוצת תת-החיזוי מורכבת באופן מובהק מסרטים עצמאיים (Indie Films) קטנים מאוד או מסרטים זרים (שאינם דוברי אנגלית) בעלי ציונים ריאליים חריגים (מעל 9.0). מאחר שלסרטים אלו אין את "תווי האיכות" הממסדיים שהמודל מחפש) כגון שחקני A-list, תקציבי עתק, או שיוך להפקה אמריקאית רחבה, (המודל מייצר עבורם תחזית זהירה במרכז ההתפלגות. המודל אינו מודע לכך שציונם הגבוה במציאות אינו משקף קונצנזוס עולמי, אלא נובע ממדגם הצבעות קטן, מוטה וממוקד של מעריצים אדוקים או אנשי תעשייה מקומיים.

3.5 השוואה רגרסיבית וארכיטקטונית בין המודלים

בחינת 20 החריגים ומידת החפיפה הסטטיסטית:

חילוץ והצלבה של רשימות 20 החריגים הקיצוניים ביותר משני המודלים (Random I Elastic Net - Forest) מעלים כי קיימת חפיפה מבנית גבוהה מאוד ביניהם (רובם המוחלט של מקרי הקיצון, כגון *Zwischen Glück und Krone*, *Rape of the Soul*, *Il Santo Veleno* -מופיעים בשני הצינורות במקביל. חפיפה סימולטנית זו מהווה הוכחה מתודולוגית לכך שלב הבעיה אינו נעוץ בכשל אלגוריתמי ספציפי של מודל כזה או אחר, אלא במגבלת המידע המובנית במערך הנתונים. (Data-Driven Boundary). ישנם סרטים שבהם הציון הסופי נקבע על ידי משתנים סוציולוגיים ותרבותיים חיצוניים (כמו תופעות רשתיות) שפשוט אינם קיימים בפיצ'רים המבניים של הסרט, ולכן מייצרים תקרת זכויות עבור כל ארכיטקטורה.

דינמיקת יחסי הגומלין: כאשר מודל אחד טועה, האם השני מצליח יותר?

התשובה לשאלה זו חיובית ומציגה בצורה מרתקת את היתרון ההנדסי של מודל האנסמבל הלא-ליניארי. בניתוח מעמיק של הסרטים שבהם מודל ה-Elastic Net-הליניארי שגה באופן קטסטרופלי, ניכר כי מודל ה-Random Forest-הצליח לבצע תיקון משמעותי ומיתן את עוצמת השגיאה בצורה ניכרת. נבחן שתי דוגמאות בולטות מתוך נתוני פלט הריצה:

- Vixen Highway 2006: It Came from Uranus!: סרט כושל ונישתי במיוחד שקיבל דירוג ריאלי קיצוני של 1.2. מודל ה-Elastic Net-בשל אילוציו הליניאריים, שקלל את המאפיינים והניב תחזית מופרכת לחלוטין של 8.01 (שגיאה חיובית עצומה של +6.81). מנגד, מודל ה-Random Forest זיהה את השילוב הלא-שגורתי והחריג של הפיצ'רים, ומיתן את התחזית באופן דרמטי ל-5.28 (צמצום השגיאה ל-4.08+ בלבד). מודל העצים קירב את החיזוי למציאות בכמעט 3 נקודות דירוג שלמות.
- Zen Comedy: יצירה ייחודית בעלת דירוג גבוה במיוחד של 9.8 במאגר. מודל ה-Elastic Net-סבל כאן מפסימיות יתר קשיחה וחוזה סביב מרכז ההתפלגות ציון של 5.37 (שגיאה שלילית של -4.42). אלגוריתם ה-Random Forest-הפגין גמישות רבה יותר, הצליח לחרוג מהממוצע הגלובלי, וניפק תחזית מדויקת יותר של 6.38 (שגיאה של -3.41), ובכך שיפר את כושר הניבוי בנקודה שלמה.

- שגיאות אינהרנטיות למודל הליניארי (Elastic Net): מגבלתו המרכזית של ה-Elastic Net- נובעת מאכיפת קשר ליניארי קבוע (Constant Marginal Effect) עבור כל פיצ'ר בנפרד. בעולם האמיתי, השפעה של פיצ'ר מסוים (למשל, אורך סרט ארוך או שיוך לז'אנר מסוים) תלויה לחלוטין בקונטקסט של משתנים אחרים (שפה, שחקנים וכו'). ה-Elastic Net- נכשל לחלוטין במקומות שבהם קיימות אינטראקציות לא-ליניאריות מורכבות (Interactions), והוא נוטה לייצר תחזיות קיצוניות ומנותקות (כמו ציוני 8 לסרטים כושלים) רק בגלל שלסרט יש צירוף של 2-3 עמודות קטגוראליות "חיוביות".
- שגיאות אינהרנטיות למודל האנסמבל (Random Forest): מודל ה-Random Forest- מפגין רובוסטיות רבה יותר מפני שגיאות קיצון מנותקות בזכות מנגנון המיצוע של מאות עצי החלטה Variance Reduction באמצעות Bagging עם זאת, נקודת התורפה הייחודית שלו קשורה לחוסר יכולתו לבצע אקסטרפולציה (Extrapolation) מעבר לטווח הערכים שנצפו בבסיס הנתונים, והוא מושפע לרעה במקרים שבהם דאטה חסר או דליל (Data Sparsity) גורם לפיצול שגוי בעלים העמוקים של העצים, מה שמוביל להטיה מותנית בקבוצות מיעוט.

4.5 מתווה אופרטיבי להנדסת מאפיינים עתידית (Proposals for Improvement)

על בסיס התובנות הסטטיסטיות המעמיקות שהופקו מניתוח השגיאות והחריגים, אנו מציעים שלושה פיצ'רים הנדסיים מורכבים וחדשניים לקראת שלבי הפיתוח הבאים, שמטרתם לטפל ישירות בכשלים המבניים שזוהו:

1. מדד מוניטין משוקלל של אנשי מפתח: (Talent/Production Historical Index) כפי שראינו במקרי הבוחן של סרטי האינדי, משתני המבנה הנוכחיים אינם מבדילים בין הפקה עצמאית חובבנית להפקה קולנועית מקצועית. הפיצ'ר המוצע יחשב את תוחלת הציון המותנית (Conditional Expectation) של סרטי העבר עבור הבמאי או חברת ההפקה הספציפית. מדד זה ישמש כאינדיקטור חזק לאיכות הפקה צפויה ויאפשר למודל לבצע סגמנטציה חדה בין סרטי שוליים ליצירות איכותיות עוד לפני יציאתן לאקרנים.
2. מדד רגישות פוליטית ותרבותית מבוסס טקסט: (Socio-Political Friction & Topic Sensitivity Index) תופעות של "Review Bombing" נובעות ישירות מהקשרים תרבותיים, דמויות מעוררות מחלוקת או נושאים פוליטיים נפיצים. הפיצ'ר יתבסס על הפעלת מודלי NLP (כגון ניתוח סנטימנט או קידוד תמטי) על עמודות ה-plot או כותרת הסרט, ויחשב מדד רציף המייצג את "מידת הנפיצות הציבורית" של התוכן. משתנה זה יאותת למודל להנמיך או להגמיש את התחזית עבור סרטים בעלי פוטנציאל גבוה למתקפות הצבעה קיצוניות ברשת.
3. מדד אמינות המדגם וצפיפות נפח הצבעות: (Sample Reliability & Niche Density Proxy) כדי לפתור את הטיית תת-החיזוי בסרטים זרם-מרכזי לעומת סרטים נישתיים קטנים (שם הציון מוטה על ידי מדגם מצומצם של אנשי צוות), ניצור פיצ'ר אינטראקציה נומרי מורכב המשלב את מדד הנישתיות של הז'אנר עם שפת המקור ומדינת ההפקה (למשל: ספירת השכיחות היחסית של קומבינציית המאפיינים בדאטה הכללית). פיצ'ר זה יהווה פרוקסי (Proxy) מוקדם לנפח ההצבעות הצפוי (Vote Volume) ויסמן למודל מתי מדובר בסרט קטן בעל סיכון גבוה לציונים קיצוניים מוטים, ובכך ימנע שגיאות תת-חיזוי שמרניות.


6. ניתוח הוגנות (Fairness Analysis)

1.6 הוגנות לפי מדינת המקור

קבוצה	מספר סרטים	RMSE	MAE
US	22,471	0.958	0.726
Non-US	93,089	1.157	0.889

2.6 הוגנות לפי עשור הוצאת הסרט

עשור	מספר סרטים	RMSE	MAE
s1910	171	0.847	0.636
s1920	785	1.038	0.790
s1930	3,121	0.848	0.646
s1940	3,292	0.839	0.646
s1950	4,602	0.898	0.696
s1960	6,208	1.006	0.796
s1970	7,969	1.033	0.812
s1980	9,631	1.075	0.839
s1990	10,213	1.079	0.844
s2000	17,555	1.147	0.878
s2010	33,605	1.178	0.893
s2020	18,405	1.244	0.948



דיון מעמיק בממצאים והסברים תיאורטיים:

1. הטיית מדינת המקור (Origin Bias): מהתוצאות עולה כי המודל מדויק משמעותית עבור סרטים אמריקאיים (US) לעומת סרטים משאר העולם (Non-US), עם הפרש של כ-20%

ברמת השגיאה RMSE (של 0.9584 מול 1.1571) תעשיית הקולנוע בארה"ב פועלת תחת תבניות הפקה קשיחות ומובנות יחסית (נוסחאות הוליוודיות לאורך וז'אנרים). המודל מצליח ללמוד תבניות אלו היטב. לעומת זאת, סרטים בינלאומיים מציגים שונות תרבותית עצומה ומדורגים על ידי קהלים מקומיים בעלי דפוסי הצבעה שונים, מה שמקשה על הגעה לרמת דיוק זהה.

2. הטיית ציר הזמן (Decade Degradation) קיים קשר מונוטוני מובהק – ככל שהסרט חדש יותר, השגיאה של המודל הולכת ומחריפה! עבור סרטים משנות ה-40 השגיאה נמוכה מאוד ($RMSE = 0.8391$), בעוד שעבור סרטים משנות ה-2020 היא מזנקת ל-1.2436 (הרעה של כ-48% בדיוק!). תופעה זו מוסברת על ידי "אפקט המסננת ההיסטורית" – סרטים ישנים שקיימים כיום במאגר הם לרוב הקלאסיקות הגדולות ביותר ששרדו את מבחן הזמן, וציוניהם קונצנזואליים. לעומת זאת, בעידן המודרני ומהפכת הסטרימינג מיוצרים עשרות אלפי סרטים בשנה ברמות איכות משתנות באופן קיצוני, והצבעות הקהל מושפעות מטרנדים רגועים ברשתות החברתיות, מה שהופך את הדירוג להרבה פחות צפוי.

דיון בהשלכות המודל על שימוש מעשי ומגבלות: Missingness ממצאי ניתוח ההוגנות המקיף מעלים חששות רגולטוריים ועסקיים מהותיים לגבי פריסת המודל במערכות מסחריות בפועל. לאור הפערים המובהקים שזוהו, לא ניתן בשום אופן לסמוך על תחזיות המודל עבור סרטים מודרניים (משנת 2010 ואילך) המופקים מחוץ לארצות הברית. (Non-US) בקטגוריות אלו רמת השגיאה (RMSE) מזנקת בעשרות אחוזים אל מעבר לממוצע, והמודל מפגין בהן חוסר הוגנות סטטיסטית קשיחה. בנוסף, חלוקת חסרי-הנתונים (missingness) במערך הנתונים – כגון סרטים שבהם שדה התקציב (budget) חסר לחלוטין במאגר – מהווה כשלעצמה פרוקסי (Proxy) מובהק ומנבא חזק לסרטים עצמאיים, נישתיים או דלי אמצעים. היעדר הנתונים (Missingness) משתלב באופן ישיר עם ההטיה המובנית (Bias) של האלגוריתם נגד יצירות שאינן שייכות לזרם המרכזי (Mainstream), ומחריף את העיוות הסטטיסטי לרעת קולנוע בינלאומי ועצמאי

7. חשיבות פיצ'רים Top 5 – לכל מודל

בהתאם לסעיף 4 במטלה, חולצו חמשת הפיצ'רים המשפיעים ביותר מתוך שני המודלים עבור Elastic Net לפי גודל המקדמים הסטנדרטיים, ועבור Random Forest לפי מדד ה Gini Feature Importance המבוסס על הפחתת האי-טוהר בעצים.

להלן הטבלה הרשמית והמדויקת של הפיצ'רים המובילים וכיוון השפעתם על החיזוי כפי שהופקו בריצה:

Elastic Net – Top 5 1.7

פיצ'ר	Coefficient	כיוון
num_genre_Horror	-0.4443	שלילי (-)
num_genre_Documentary	0.4311	חיובי (+)
num_genre_Thriller	-0.3407	שלילי (-)

num_genre_Sci-Fi	0.2996-	שלילי (-)
num_runtimeMinutes	0.2420	חיובי (+)

Random Forest – Top 5 2.7

פיצ'ר	Importance	כיוון
num_genre_Documentary	0.3206	חיובי (+)
num_genre_Horror	0.2219	שלילי (-)
num_runtimeMinutes	0.1807	חיובי (+)
num_genre_Drama	0.0940	חיובי (+)
num_is_post_imdb	0.0406	שלילי (-)

3.7 פירוש הממצאים

דיון והשוואה בין המודלים

- הסכמה קונצנזואלית על המשתנים המובילים: קיים מתאם מרשים והסכמה מלאה בין המודל הליניארי (Elastic Net) למודל מבוסס העצים (Random Forest) לגבי שני הפיצ'רים המשמעותיים ביותר בחיזוי דירוג. שניהם קובעים כי הז'אנר דוקומנטרי (Documentary) הוא בעל השפעה חיובית חזקה (סרטים תיעודיים מקבלים ציונים גבוהים יותר מהקהל הממוקד הצופה בהם) בעוד שהז'אנר אימה (Horror) הוא בעל משקל שלילי כבד (סרטי אימה נוטים לקבל באופן עקבי ציונים נמוכים בממוצע במאגר IMDb).
- משקל אורך הסרט (runtimeMinutes): שני המודלים מזהים שמשך סרט ארוך יותר מתואם חיובית עם ציון גבוה יותר. הדבר מתיישב עם התעשייה שבה סרטים ארוכים נתפסים לרוב כהפקות "אפיות" או דרמות מושקעות הזוכות ליחס אוהד יותר.
- נקודת השוני והיתרון של ה Random Forest-מודל ה Random Forest-הצליח להכניס לחמישייה המובילה את הפיצ'ר ההנדסי שייצרנו is_post_imdb והעניק לו כיוון השפעה שלילי (סרטים שיצאו בעידן הדיגיטלי שלאחר 1991 זוכים לתחזית שמרנית ונמוכה יותר מסרטים קלאסיים). יכולתו של ה Random Forest-לשלב את הפיצ'ר הזה בצורה לא-ליניארית בתוך ענפי העצים היא זו שהעניקה לו את יתרון הדיוק הדרמטי ופריצת תקרת הביצועים על פני ה-Elastic Net.

8. סיכום, מגבלות והמלצות לעתיד

1. מסקנה מתודולוגית: פרויקט זה הוכיח את החשיבות של שימוש ב-Pipeline מובנה וב-Cross-Validation נקי למניעת Data Leakage. מבין המודלים שנבחנו Random Forest Regressor, נקבע כמודל הסופי והמוביל לחיזוי דירוגי סרטים, בזכות יכולתו ללמוד קשרים מורכבים בין מאפייני הסרט השונים.
2. מגבלות המודל והדאטה: המודל מוגבל קשיחה על ידי המשתנים היבשים הזמינים טרם יציאת הסרט. מניתוח השגיאות וההוגנות עולה כי הקושי המרכזי של המודל נעוץ בחיזוי סרטים מודרניים (משנות ה-2000 והלאה) וסרטים זרים (Non-US) שם קיים רעש תרבותי רב ודפוסי הצבעה תנודתיים ב-IMDb-כמו תופעות של Review Bombing או הטיית קבוצות מעריצים קטנות

1.9 מניעת זליגת נתונים (Data Leakage)

בכדי להבטיח שהמודל שלנו מסוגל להכליל נתונים חדשים ולנבא במדויק את דירוג הסרט טרם יציאתו לאקרנים, הקפדנו על מניעת זליגת נתונים (Data Leakage) באופן הרמטי בשני רבדים מרכזיים:

1. מניעת זליגת נתונים ברמת המאפיינים: (Temporal Leakage)

כדי לדמות מצב חיזוי אמיתי (בו הסרט טרם יצא לקולנוע), וידאנו שאף נתון "עתידי" לא דולף לתוך מטריצת הפיצורים שלנו.

- הסרת משתנים עתידיים: במסגרת הפונקציה `prepare_data`, הסרנו באופן מוחלט את העמודות `numVotes` (כמות המדרגים) ו `BoxOffice` (הכנסות קופות). נתונים אלו מצטברים רק לאחר הפצת הסרט, ושימוש בהם היה גורם למודל "להציץ לעתיד" ולייצר תחזיות אופטימיות שאינן אפשריות במציאות.
- הפרדת משתנה המטרה: וידאנו שעמודת המטרה `averageRating` מופרדת לחלוטין ממטריצת הפיצורים (X) כבר בשלבים הראשונים, ואינה משתתפת בשום צורה בתהליך הנדסת המאפיינים (Feature Engineering)

2. מניעת זליגה סטטיסטית בתהליך האימון: (Methodological Leakage)

הסכנה הגדולה ביותר בלמידת מכונה היא זליגת מידע מסט הבדיקה (או הוולידציה) לתוך סט האימון דרך פעולות סטטיסטיות מקדימות. כדי למנוע זאת, יישמנו את הארכיטקטורה הבאה:

- שימוש ב-Pipeline-נעול: כל פעולות העיבוד המקדים הסטטיסטיות – השלמת ערכים חסרים, (SimpleImputer), נרמול הנתונים, (StandardScaler) הרחבה פולינומית (PolynomialFeatures) וקידוד קטגוריאלי – (OneHotEncoder) הוגדרו באופן קשיח בתוך אובייקט Pipeline של Scikit-Learn
- בידוד בתוך ה-Cross Validation: את ה-Pipeline כולו הזנו לתוך אלגוריתם ה-GridSearchCV-שביצע 10-Fold CV-מנגנון זה מבטיח שבכל איטרציה, החישובים הסטטיסטיים (כמו חישוב חציון להשלמת חסרים או חישוב ממוצע וסטיית תקן לנרמול) מחושבים אך ורק על 9 קבוצות האימון. (Training Folds) לאחר מכן, הטרנספורמציות מוחלות (transform) כפי שהן על קבוצת הוולידציה ה-10 שנותרה בחוץ.
- הפרדת הנדסת תכונות בסיסית מסטטיסטיקה: פונקציית ה-`prepare_data` שלנו תוכננה להיות דטרמיניסטית ו"בטוחה". היא מבצעת אך ורק חילוף מידע נקי (כמו ספירת מילים, חילוף ז'אנרים והמרה לוגית), ללא חישובים הנשענים על התפלגות הנתונים הכללית, ובכך מאפשרת הפעלה בטוחה על כל שורת קלט חדשה מבלי לחשוף מידע מסטים אחרים.

1.10 שימוש בבינה מלאכותית (AI Usage Log)

במהלך הפרויקט נעשה שימוש בכלי בינה מלאכותית (gimini) לצורך ייעוץ והכוונה. להלן נקודות ההתייעצות העיקריות:

מה שינינו בעקבות התשובה	מה שאלנו	נושא ההתייעצות
הוספנו את is_post_imdb - num_a_list_actors בעקבות ההמלצה.	אילו פיצ'רים הנדסיים עשויים להוסיף ערך לחיזוי דירוג סרטים?	בחירת פיצ'רים הנדסיים
בחרנו ב-MultiLabelBinarizer לפיצול לעמודות בינאריות.	איך מקודדים שדה genres שמכיל מספר ז'אנרים לסרט?	טיפול בז'אנרים רב-ערכיים
השתמשנו ב-GridSearchCV עם alpha ב-[1, 0.1, 0.01, 0.001] ו-l1_ratio ב-[0.9, 0.5, 0.1].	מהו טווח סביר ל-alpha ול- l1_ratio?	בחירת היפר-פרמטרים ל- Elastic Net
עטפנו את כל העיבוד ב- Pipeline ועברנו את ה-Pipeline ל-cross_val_score.	איך לוודא שה-Scaler לא רואה את סט הבדיקה?	מניעת Data Leakage
השתמשנו ב-seaborn barplot עם RMSE ו-MAE צמודים לכל קטגוריה.	איך להציג ויזואלית פערי ביצועים בין תת-קבוצות?	ניתוח הוגנות